WELD：语言模型能多好地构建和调整动态工作流？

Zhixuan Liu
Northeastern University

Qi Yan*
Northeastern University

Abstract

语言模型越来越多地决定智能体系统做哪些工作、如何合并结果，以及条件变化后需要修改什么。仅检查最终答案难以评价这些决策。本文提出可执行基准 WELD，将任务有效性、领域原生工作量、实际时间收益和选择性适应连接起来。基准包含五个场景、20 个来源簇、100 个父任务，每个任务具有初始、相关变化和无关变化三种条件。十个 API 模型产生 6,000 个阶段结果，另完成 8,874 次原生执行回放。在 5,006 对有效初始方案中，2,241 对存在工作量支配关系，372 对存在资源取舍；187 对方案的工具调用数相同，但主要工作量不同。中等任务中，在线时间节省落后于工作量节省，按父任务等权平均相差 31.6 个百分点；扣除本地准入等待后仍相差 14.5 个百分点，而原生回放往往兑现了节省。初始结果有效时，无关变化后的有效率为 99.3%，相关变化后为 54.6%。WELD 用成功工作、实际收益和维护行为共同刻画工作流有效性。

1 引言

工作流决定一个智能体系统读取什么、执行哪些测试、共享哪些结果，以及重复哪些工作。两个模型可以提交相同的正确答案，却采用不同的执行方案。一条查询既可以处理请求中的少量对象，也可以聚合整个数据库。复用一份观察既可以省去调用，也可以保留来自错误版本的结果。最终答案说明任务是否完成，工作流评价还需要说明这些工作是否被有效组织。

近期基准已经把工作流执行变成具体的评测对象。ClawArena-Team 固定工人池，通过任务、权限和模态路由的执行评分评价经理模型 (Xiong et al., 2026)。这一设计使模型决策能够在工人受控时被研究。下一步问题位于实际执行内部：成功方案可能请求过多工作，局部节省可能不能按比例缩短完成时间，部分条件变化也可能破坏已有正确结果。经理层面的综合评分没有展开这三个关系。

*通讯作者。

本文研究**工作流有效性**：模型运行中决策、这些决策引发的工作，以及它们持续维持的有效结果之间的关系。测量需要保留工作量的领域含义。一次回归用例、一次数据库进度回调和一条遥测记录是不同资源。时间需要区分原生执行、模型交互和服务等待。适应需要从模型自己完成的状态开始，才能评价已有工作的复用与修复。

我们提出 WELD，即 Work, Execution, and Lifecycle Diagnostics。模型通过迭代接口创建并修改数据流，固定原生工人执行每个批次并返回中间观察。可执行任务契约同时检查提交结果与证据或应用状态。版本化产物、计划修订和实际事件把意图与行为连接起来，支持三个直接比较：正确方案需要多少工作；工作节省兑现了多少时间收益；已有正确方案如何响应相关与无关变化。

基准覆盖图检索、代码审查、数据库分析、遥测诊断和业务操作。100 个父任务来自 20 个来源簇，每个任务具有三个条件，每个模型独立生成两次。简单任务提供可比较的有效执行，中等任务保留批处理、范围选择、复用和多源整合决策。十模型实验共得到 6,000 个阶段结果和 8,874 次忠实原生回放。结果显示，正确率、工作量、在线收益和变化适应提供互补信息，WELD 将这些信息落实到同一套执行记录。

2 相关工作

工作流评价。 WorFBench 构建多场景工作流任务，以子序列和子图匹配评价生成结果，并报告下游表现和时间 (Qiao et al., 2025)。结构匹配不能说明另一种有效分解需要多少原生工作。FlowMind 将任务执行与工作流重建分离，并提出 FlowBench(Liu et al., 2026)。它提供了从执行到结构的生成方法；本文进一步比较已执行方案的资源及其后续修订。OrchBench 在给定 DAG 上评测任务分配和信息传递，通过确定性模拟返回质量、工期和 token 成本 (Ren et al., 2026)。WELD 让模型选择实际调查，并

测量原生操作和观察到的时间。

智能体评价。 AgentBoard 提出细粒度进度率与多轮智能体分析工具 (Ma et al., 2024)。子目标进展与完成这些目标所需的工作量是互补信息。AppWorld 提供可执行应用和允许多种解法的状态测试 (Trivedi et al., 2024)。WELD 采用结果验证，并在多个领域增加配对工作量测量和完成状态后的变化。ClawArena-Team 通过受控工人测量管理行为，包含权限、模态路由和任务结果 (Xiong et al., 2026)；其费用分析已显示成本与质量可能分离。本文关注原生节省是否兑现为在线收益，以及变化后需要哪些新增工作。

效率与评价单位。 Kapoor et al. (2024) 主张联合评价准确率与成本，并改进留出集和复现纪律。BIRD 在真实数据库上评价 SQL 正确性和执行效率 (Li et al., 2023)。这些工作建立了效率评价的必要性。WELD 将领域工作向量、实际时间和更新行为连接到同一条工作流生命周期。本文的指标覆盖表按具体操作定义进行比较，并保留模拟量与实际执行量的区别。

3 WELD：可执行测量

3.1 模型生成的动态数据流

任务表示为 $(x, c, \mathcal{O}, V)$，分别为冻结的源世界、公开要求、允许算子和可执行验证器。每一轮，模型读取任务、当前节点、版本化观察和运行反馈，创建包含算子、参数和依赖的节点。参数可以引用先前产物。运行时执行一个批次后返回观察，模型再决定下一步调查、修改待执行范围、补充依赖或提交结果。

四个确定性工人槽运行领域算子，包括图遍历、源码读取、回归探针、只读 SQL、遥测聚合和本地应用状态变更。共享变换支持筛选、分组、投影、排序与聚合。模型既可以调用原生聚合算子，也可以组合底层操作。长输出即使在界面中被截断，完整内容仍可通过产物引用访问。

初始图、后续修订和真实执行事件分别保存。每份产物记录生产事件、输入产物、源版本和内容哈希。更新阶段继承完成检查点，历史工作保留身份，但不进入新增资源总量。图1展示执行和测量之间的联系。

3.2 有效性和比较池

对结果 y、观察 E 和最终状态 s，定义

$$Q_1 = \mathbf{1}[y, s\text{满足输出契约}], \tag{1}$$

$$Q_2 = \mathbf{1}[E, s\text{满足支持要求}], \tag{2}$$

$$\mathsf{G} = Q_1 Q_2. \tag{3}$$

只读任务验证必需值、对象或测试身份及观察的适用性；业务任务检查实际状态和保护条件。不同正确分解可以通过同一契约。冻结的等价性审计允许等价 SQL 和图访问方式。证据自动连接到执行产物，因而测量的是实际支持，而非引用格式。

所有计划阶段均进入无条件有效率分母，未提交计为零。工作与时间比较额外要求两个方案在相同父任务、初始条件和生成序号上均通过 G。正确率与比较池同时报告，成功较少的模型既有较低质量分数，也提供较少有效比较。

3.3 工作量、时间与收益

设 $\mathcal{E}_\tau$ 为工作流中具有唯一身份的执行事件，则

$$\mathbf{W}(\tau) = \sum_{e \in \mathcal{E}_\tau} \mathbf{w}(e). \tag{4}$$

向量坐标保留原生单位，包括图记录、回归用例、数据库进度回调、指标值、日志和链路行、业务记录和写入以及数据变换。失败和重试发生了工作就计入。模型请求使用独立台账，保存 token、费用回执、未知费用与重试。

如果全部原生坐标均不增加且至少一个严格减少，则方案 a 在记录的工作量上支配 b：

$$\begin{aligned} &\forall j \in J : W_j(a) \le W_j(b), \\ &\exists j \in J : W_j(a) < W_j(b). \end{aligned} \tag{5}$$

J 包含该场景所有活跃原生坐标，排除模型请求。等量和资源取舍分别保留，不需要把用例、记录和写入换算为一个分数。

在线时间覆盖运行开始至完成，包含模型请求和本地准入等待。评分在之后执行。经理与工人区间并集分别为 U_M, U_W，重叠为 O，则

$$T = U_M + U_W - O + T_{\text{other}}. \tag{6}$$

我们另报告扣除本地准入等待的在线时间，服务端等待仍包含其中。原生回放复用保存的模型响应，不再次调用 API，在一和四个工人槽上各执行三次，以工人活动区间并集的中位数计时。

对工作量占优的低工作方案 ℓ 及高工作方案 h，预先指定场景主要坐标 j_s，定义

$$S_W = 1 - \frac{W_{j_s}(\ell)}{W_{j_s}(h)}, \quad S_T = 1 - \frac{T(\ell)}{T(h)}. \tag{7}$$

两者差 $D = S_W - S_T$ 表示兑现差距。$0 < S_T < S_W$ 即有收益但低于工作节省比例。配对要求主要工作量不同、分母为正、每阶段只有一次物理尝试；在线比较还要求采集批次和准入配置相同。

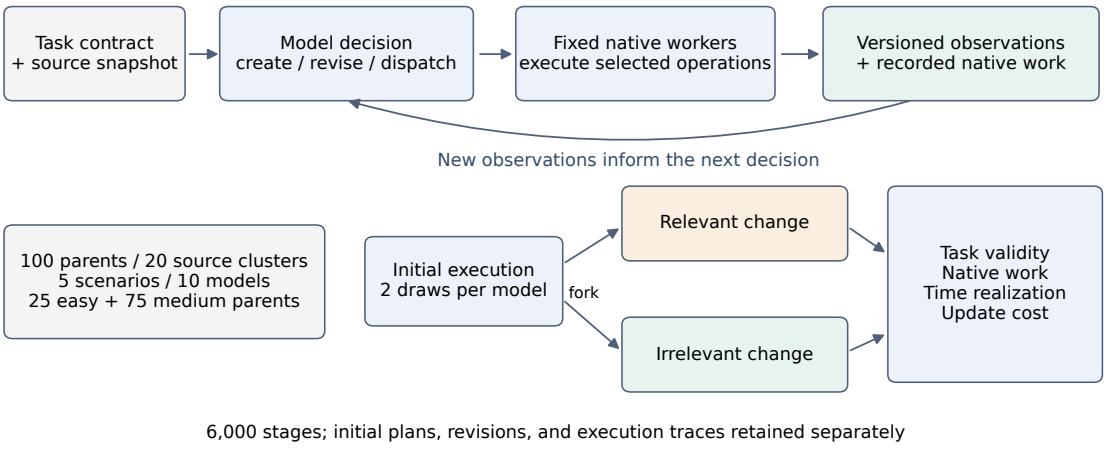


Figure 1: 模型在批次之间读取观察并决定后续工作。相关变化和无关变化从相同检查点分叉；原生回放固定模型响应，改变工人容量。

3.4 选择性适应与新增代价

从有效初始执行出发，对相关或无关变化 u，定义

$$A_u = \frac{\sum_{p,r} \mathsf{G}_{p,r,0}\mathsf{G}_{p,r,u}}{\sum_{p,r} \mathsf{G}_{p,r,0}}. \tag{8}$$

相关变化改变要求、版本或源状态；无关变化保持目标不变。两个分支继承同一检查点。仅新增事件计入 $\Delta\mathbf{W}, \Delta C, \Delta T$，完整路径只计算一次前缀。

独立前缀审计将旧答案和旧证据置于新条件下重新验证，区分答案需要改变、证据需要更新、二者均需改变以及均可复用。只读源版本变化时，验证器可以重新执行旧观察，判断其结果是否仍适用；这些验证工作独立记账，不归给模型。

3.5 汇总与测量验收

质量表分别报告五个场景的 G，以及场景等权平均。每场景有 20 个父任务、三个条件、两次重复，因此总体宏平均等于每模型有效阶段数除以 600。工作、时间、适应和费用不混成加权总分。

配对观察共享父任务和模型结果。兑现差距先在父任务内部平均，再以父任务为单位进行 4,000 次 bootstrap，得到 95% 百分位区间。适应分析还按场景内来源簇与簇内父任务重采样，并提供两两共同支持集和逐来源删除结果。

验收覆盖正例、错误身份、过期版本、等价表示和失败执行。最终审计核对逻辑阶段、物理请求和产物引用。8,874 次原生回放全部得到有效结果，且原生观察与工作向量与原记录一致。附录说明计数不变量与数学性质。

4 任务集构建

五个场景各包含 20 个父任务，其中简单五个、中等十五个。每个父任务生成初始、相关变化、无关变化三张卡片，共 300 张。每模型对每卡片生成两次。图2展示来源与改造过程。

图检索。 从 STaRK MAG 图构建组合查询 (Wu et al., 2024)，使用已有共享切片以及 Stanford、MIT、东京大学三个机构邻域。保留作者发表记录闭包和论文引用。简单任务汇总一个作者的论文数、引用数和最高引用论文；中等任务组合作者并读取选定论文的参考文献。相关变化把年份范围从 2010–2014 扩展到 2000–2024。先过滤、广泛读取以及复用旧记录产生不同工作量。

代码审查。 使用 Requests 2.32.5、ItsDangerous 2.2.0、packaging 25.0 和 python-dotenv 1.1.1(Python Software Foundation and Requests contributors, 2025; Pallets and ItsDangerous contributors, 2024; Python Packaging Authority, 2025; python-dotenv contributors, 2025)。围绕重定向与复制、时间边界、版本约束和解析行为，构建干净及人工植入变更的快照。公开测试契约提供预期行为，原生探针读取当前实现的行为。模型输出审查结论和精确失败用例身份。中等任务增加范围内用例和跨模块要求。相关变化替换实现版本。所有人工变更均保留来源标签。

数据库分析。 BIRD 的 debit、financial 数据库以及 Chinook、Northwind 提供四个来源簇 (Li et al., 2023; BIRD team, 2024; Rocha, 2026; Northwind SQLite3 contributors, 2026)。任务要

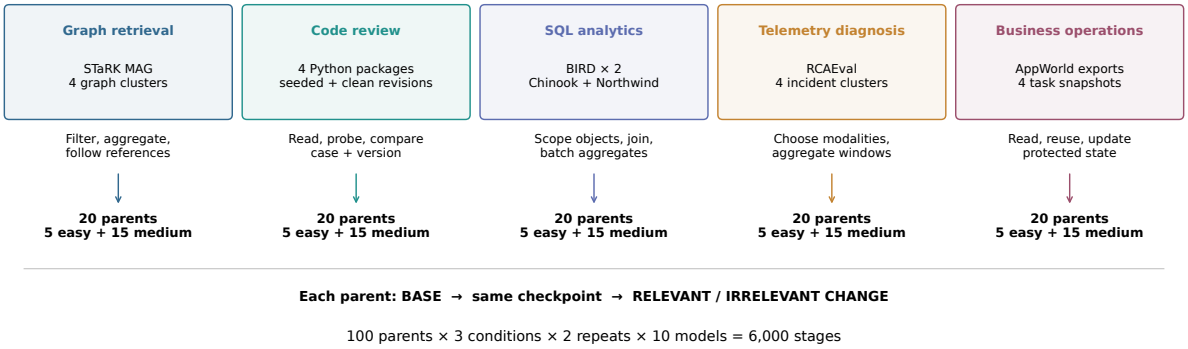


Figure 2: 冻结来源、领域任务与条件分叉。每个场景具有四个来源簇和 20 个父任务。难度变化减少或增加输出负担，同时保留范围、批处理、复用和更新选择。

求消费、区域贷款或客户采购等绑定对象的聚合结果。中等任务增加对象和字段。相关变化替换请求对象或修改一个值。模型可使用范围化聚合算子或只读 SQL，暴露批处理、广泛扫描和重复查询的工作差异。

遥测诊断。 RCAEval 提供 Online Boutique 与 Train Ticket 的指标、日志和链路 (Pham et al., 2024)。原有 checkout 事件及三个新增服务事件组成四个来源簇。任务在公开分割时间前后比较指标均值比；中等任务增加链路时长比和日志匹配计数。相关变化移动分割点，原始遥测保持不变。真值来自这些可观察诊断量。

业务操作。 四个 AppWorld 任务快照提供播放列表、用户和支付记录 (Trivedi et al., 2024)。我们将记录导出至本地确定性状态适配器，构建播放、离线下载和支付对账任务。更新改变时长、增加列表或计入部分支付。多个列表可以满足时长，既有下载可以复用，写入按成员替换请求金额。验证器检查实际效果及受保护状态。结果属于这套改造任务。

构建控制。 冻结源数据分别生成公开任务卡与私有预期结果。要求明确对象身份、数值容差、状态义务及允许操作。参考执行检查可满足性，受控突变检查拒绝能力。20 个来源簇保留共享语料关系：MAG 邻域共享部分引用，AppWorld 快照共享生成数据。此前极复杂任务独立归档，不并入本轮主实验。

5 实验设置

十模型均使用相同任务接口和固定工人，每模型 600 个逻辑阶段。初始阶段最多 12 轮决策，更新最多八轮，每轮最多 8,192 输出 token，四个原生工人槽并行执行。采用端点默认采样，两次独立生成。开发阶段冻结各端点兼容的推理配置，正式请求使用 JSON 对象接口。格式失败、工具失败和未提交均保留在质量分母中。

各采集批次保留配置记录。历史模型与最终新增五模型使用相同任务契约和最终等价性规则。已确认传输中断按记录策略替换，错误答案不因结果不理想重跑。资源保留物理尝试，计时使用单次尝试及匹配采集条件。原生回放在共同离线批次完成；此前磁盘中断批次全部排除。最终得到 6,000 个主阶段和 8,874 次回放。

6 结果

6.1 有效性提供直接比较的基础

全部阶段有 3,873/6,000 通过 G；初始为 1,479/2,000，即 74.0%，100 个父任务全部具备有效配对。图检索、代码、数据库、遥测和业务的初始有效数分别为 291、235、343、347、263，分母均为 400。

初始有效性与生命周期有效性揭示不同表现。Gemini 3.7 Flash 的初始有效数最高，为 197/200；GPT-6 Luna 的总体有效数最高，为 559/600，相关更新恢复 165/196。GLM-5.3 Flash 初始通过 184 个，相关更新恢复 150 个。MiniMax M3 提交了全部 600 阶段，但初始只有 19 个有效结果。交付率说明接口完成，不能替代任务完成。

6.2 发现一：相同有效结果隐藏不同工作量

1,479 个有效初始执行产生 5,006 对跨模型比较。其中 2,393 对向量相等，2,241 对存在支配，372 对存在资源取舍。正确性确定了比较对象，但没有决定其工作量。

3,619 对方案的工具调用数相同，其中 187 对的主要原生工作量不同，涉及 29 个父任务。在客户审计 A14 中，Qwen3.8 Flash 和若干正确替代方案都只调用一次原生工具，但分别触

Model	Graph	Code	SQL	Telemetry	Business	All stages	Initial
Open-weight model families, served through APIs							
DeepSeek V4 Pro 0813	29.2	34.2	70.0	61.7	29.2	44.8	58.5
Kimi K2.6	52.5	48.3	78.3	67.5	65.0	62.3	76.5
Qwen3.8 Flash	84.2	40.0	88.3	65.8	56.7	67.0	79.5
Gemma 4 31B	86.7	23.3	98.3	66.7	63.3	67.7	80.5
GLM-5.3 Flash	97.5	63.3	92.5	86.7	98.3	87.7	92.0
MiniMax M3	0.0	10.0	5.8	20.8	6.7	8.7	9.5
Closed-model APIs							
Gemini 3.8 Flash	100.0	71.7	99.2	70.8	100.0	88.3	98.0
Gemini 3.7 Flash	100.0	68.3	100.0	76.7	100.0	89.0	**98.5**
Grok 4.3	41.7	18.3	57.5	49.2	17.5	36.8	48.5
GPT-6 Luna	98.3	72.5	100.0	98.3	96.7	**93.2**	98.0

Table 1: 联合有效率（%）。各场景每模型 120 阶段，总计 600 阶段；初始列为 200 阶段。总体为场景等权平均。粗体标记总体与初始最高值。所有模型均通过 API 调用。

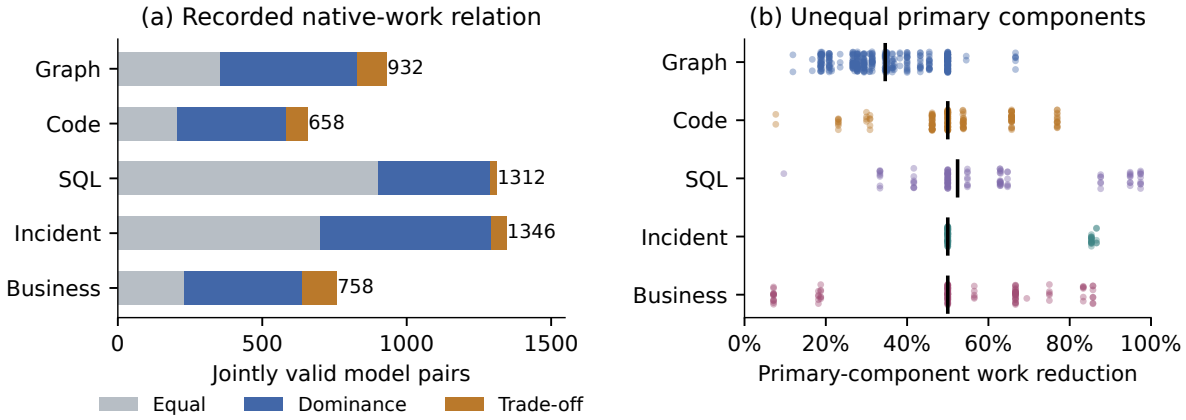


Figure 3: 5,006 对有效初始执行的原生工作量。左侧显示完整向量上的等量、支配和取舍；右侧显示场景主要坐标差异。单坐标节省需与完整向量关系共同解释。

发 39 和两次 SQLite 进度回调。这个测量代理相差 19.5 倍。“一次查询”会抹去数据库实际处理量的区别。

372 对资源取舍同样有价值：减少一种工作可能增加另一种工作。WELD 先报告向量关系，再计算主要坐标节省，因此可以根据明确资源偏好判断哪个有效方案更好。

6.3 发现二：原生节省与在线收益分离

116 对工作量占优方案满足在线采集控制。其中 29 对有正向但不足比例的时间节省，33 对时间节省为零或负，54 对至少等比例兑现。父任务等权平均兑现差距为 31.6 个百分点，95% 区间为 13.7–52.4。扣除本地准入等待后，差距缩至 14.5 个百分点，区间为 3.7–26.3。

原生层呈现不同结果。467 对四工人回放中，108 对正向衰减，27 对无正收益，332 对至少等比例兑现。父任务等权平均差距为 -6.0 个百分点，区间为 $[-13.7, 2.9]$，不表现为总体正向衰减。

进一步在相同 116 对方案上比较两个计时域，原生时间节省比扣除准入后的在线节省高 24.2 个百分点，区间为 13.9–34.5。测量把差异定位在本地执行与交互完成之间。模型请求、服务等待和运行时协调能够消耗原生收益，因此评价需要同时关注批处理、交互频率与请求工作量。

6.4 发现三：保持比修复容易

1,479 个有效初始状态中，无关变化保留 1,468 个有效结果，即 99.3%；相关变化仅得到 807 个，即 54.6%。是否需要真正修订，显著改变了后续表现。

前缀审计进一步拆解修订需求。1,183 次变化同时使旧答案和证据不足，其中 585 次恢复。228 次保留充分证据但需要改变答案，其中 168 次恢复。28 次答案仍然正确却需要新证据，只有 14 次恢复。40 次前缀仍完全有效的情况均保持有效。答案稳定与证据稳定是不同属性。

相关更新中有 632 次没有新原生调用，仅 34 次有效；无关更新中则有 1,429 次不新增原生

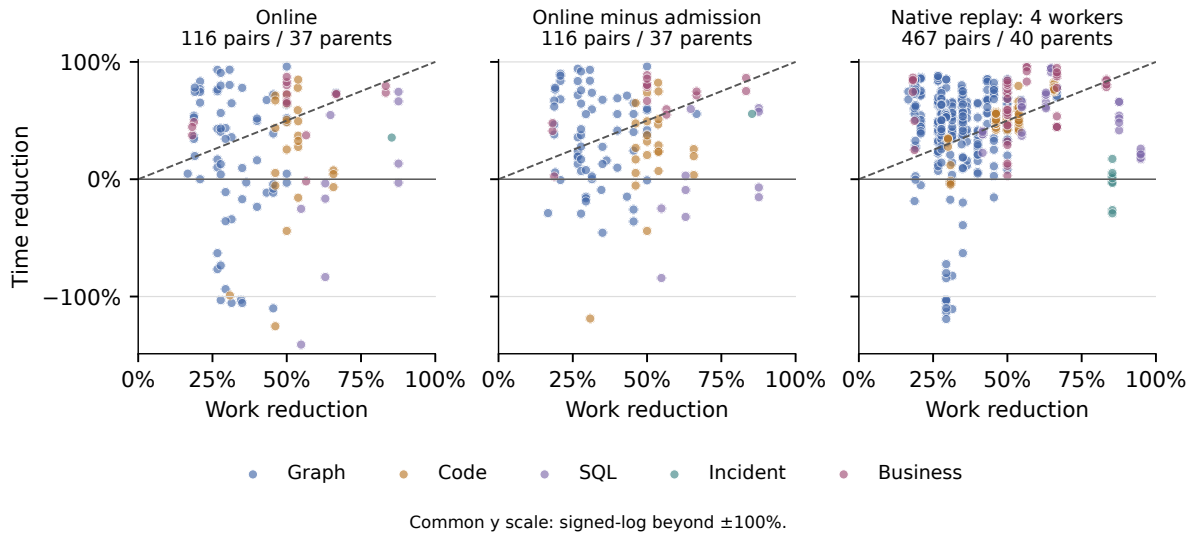


Figure 4: 中等任务的工作量节省与时间节省。在线比较为 37 个父任务上的 116 对；四工人原生回放为 40 个父任务上的 467 对。对角线表示等比例兑现；线上方与下方分别表示更多和更少的时间收益。原生时间采用工人活动区间并集。

调用且保持有效。相同的“没有继续调用工具”，既可能是合理复用，也可能是修复失败，其含义由变化后的契约和证据决定。

Gemini 3.7 和 3.8 Flash 初始有效率接近，分别为 98.5% 和 98.0%，相关更新有效率为 71.1% 和 68.9%。Luna 初始为 98.0%，相关更新为 84.2%；GLM 初始为 92.0%，相关更新为 81.5%。各条件比较池不同，配套数据提供共同支持集、来源重采样和逐来源删除分析。

7 讨论与结论

WELD 将工作流有效性落实为三个可观察关系：有效结果对应不同工作向量；原生节省可以在执行层兑现，却在线上被削弱；已完成工作流可以应对通知，却在真正变化后修复失败。每个关系都把模型决策与执行后果相连。

这些测量给出具体改进目标。模型可以学习按请求对象收缩操作范围、合并兼容调查、减少执行价值有限的交互。版本感知策略可以区分重算答案、取得新证据和保留适用状态。训练与系统优化因而能够针对观测到的失败类型，同时检查有效性和新增代价。

本文贡献是相互连接的测量协议及可执行基准：任务级验证、原生工作画像、配对计时和完成状态后的适应。十模型实验说明，评价构建和维护动态工作流的模型，需要同时保留这四类信息。

局限

WELD 使用人工构建任务和确定性工人，结果对应当前接口与端点配置。注册代码探针、聚合辅助算子和本地业务状态适配器使要求可执行，也限定了行动空间。20 个来源簇共享部分语料，两次生成提供的模型内采样有限。在线计时控制已记录的采集配置，仍保留服务端和网络波动。固定响应回放测量已生成决策的原生执行。支配关系依赖已记录坐标，SQLite 进度回调是粗粒度代理。全部十模型共同通过初始验证的交集仅八个父任务–重复单元，因此条件比较需要同时报告支持集。

伦理与复现

研究使用公开代码、基准记录和生成的应用数据。人工植入变更明确标记，支付和播放操作在隔离本地状态中执行。冻结来源记录保留许可证与归属。复现包包括任务卡、验证器、模型配置、物理尝试索引、结果表、回放检查和可编辑矢量图；不含凭据及本地账户配置。

References

BIRD team. 2024. BIRD Mini-Dev.

Sayash Kapoor, Benedikt Stroebl, Zachary S. Siegel, Nitya Nadgir, and Arvind Narayanan. 2024. Ai agents that matter. *Preprint*, arXiv:2407.01502.

Jinyang Li, Binyuan Hui, Ge Qu, Jiaxi Yang, Binhua Li, Bowen Li, Bailin Wang, Bowen Qin, Rongyu Cao, Ruiying Geng, Nan Huo, Xuanhe Zhou, Chenhao Ma, Guoliang Li, Kevin C. C. Chang, Fei Huang, Reynold Cheng, and Yongbin Li. 2023. Can LLM Already Serve as A Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs. *Preprint*, arXiv:2305.03111.

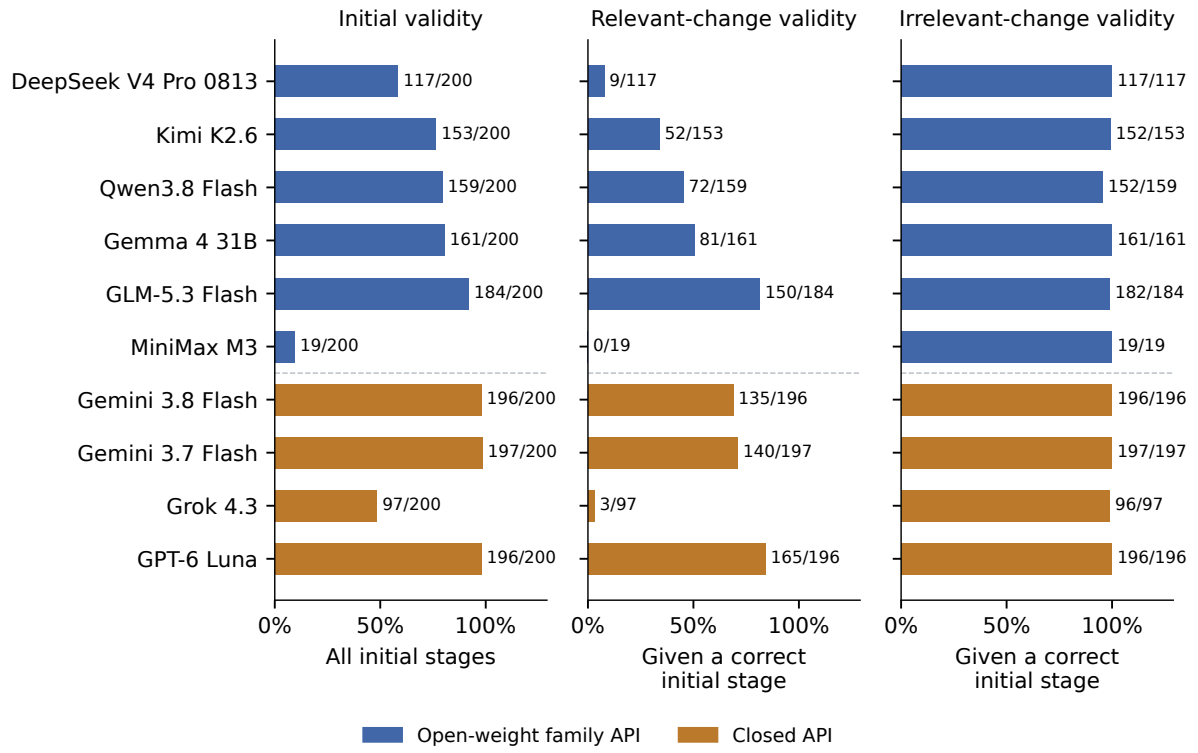


Figure 5: 初始有效性及从有效初始状态出发的适应。相关和无关变化使用图中标出的初始有效分母。开源模型家族 API 与闭源 API 分组展示。各模型条件比例使用各自比较池，两两共同支持集另行提供。

Yihao Liu, Ziyun Zhang, Zile He, and Huaqian Cai. 2026. FlowMind: Execute-Summarize for Structured Workflow Generation from LLM Reasoning. *Preprint*, arXiv:2602.11782.

Chang Ma, Junlei Zhang, Zhihao Zhu, Cheng Yang, Yujiu Yang, Yaohui Jin, Zhenzhong Lan, Lingpeng Kong, and Junxian He. 2024. Agentboard: An analytical evaluation board of multi-turn llm agents. *Preprint*, arXiv:2401.13178.

Northwind SQLite3 contributors. 2026. Northwind sqlite3. Frozen SQLite source snapshot retrieved October 2026.

Pallets and ItsDangerous contributors. 2024. ItsDangerous. Version 2.2.0; commit 096c8d42545d3b68ea21a4f890fb2b2d8979c0bd.

Luan Pham, Hongyu Zhang, Huong Ha, Flora Salim, and Xiuzhen Zhang. 2024. RCAEval: A Benchmark for Root Cause Analysis of Microservice Systems with Telemetry Data. *Preprint*, arXiv:2412.17015.

python-dotenv contributors. 2025. python-dotenv. Version 1.1.1; frozen source distribution.

Python Packaging Authority. 2025. packaging. Version 25.0; frozen source distribution.

Python Software Foundation and Requests contributors. 2025. Requests: HTTP for Humans. Version 2.32.5; commit b25c87d7cb8d6a18a37fa12442b5f883f9e41741.

Shuofei Qiao, Runnan Fang, Zhisong Qiu, Xiaobin Wang, Ningyu Zhang, Yong Jiang, Pengjun Xie, Fei Huang, and Huajun Chen. 2025. Benchmarking Agentic Workflow Generation. *Preprint*, arXiv:2410.07869.

Zhenzhen Ren, Jiyan He, Xinpeng Zhang, Zhenxing Qian, Ke Han, Shuxin Zheng, GuoBiao Li, and Xiaoqing Zhang. 2026. OrchBench: Evaluating Multi-Agent Orchestration Plans in Isolation via Deterministic Simulation. *Preprint*, arXiv:2607.25656.

Luis Rocha. 2026. Chinook database. Frozen SQLite source snapshot retrieved October 2026.

Harsh Trivedi, Tushar Khot, Mareike Hartmann, Ruskin Manku, Vinty Dong, Edward Li, Shashank Gupta, Ashish Sabharwal, and Niranjan Balasubramanian. 2024. AppWorld: A Controllable World of Apps and People for Benchmarking Interactive Coding Agents. *Preprint*, arXiv:2407.18901.

Shirley Wu, Shiyu Zhao, Michihiro Yasunaga, Kexin Huang, Kaidi Cao, Qian Huang, Vassilis N. Ioannidis, Karthik Subbian, James Zou, and Jure Leskovec. 2024. STaRK: Benchmarking LLM Retrieval on Textual and Relational Knowledge Bases. *Preprint*, arXiv:2404.13207.

Kaiwen Xiong, Haonian Ji, Shi Qiu, Zeyu Zheng, Cihang Xie, Xinyu Ye, and Huaxiu Yao. 2026. ClawArena-Team: Benchmarking Subagent Orchestration and Dynamic Workflows in Language-Model Agents. *Preprint*, arXiv:2606.31174.

A　计数性质与指标定义

事件身份。　每次物理请求和执行事件具有唯一身份。新增事件集合为 N 时，增量工作为 $\Delta\mathbf{W}=\sum_{e\in N}\mathbf{w}(e)$。重复读取同一日志只计算一次；实际重试产生新的事件身份，再次计入。导入前缀保留历史消耗并将新增消耗置零，因此完整路径满足 $\mathbf{W}_{0\to u}=\mathbf{W}_0+\Delta\mathbf{W}_u$。

单位不变性。　对坐标 j 使用正数 a_j 改变单位，同时乘两个方案的对应坐标，不改变支配不等式，也不改变 $1-a_jW_j(\ell)/(a_jW_j(h))$。这解释了为何可以保留异质原生单位，不必加权成总分。不同资源的代价偏好仍由使用场景决定。

时间可加关系。　模型与工人活动并集满足容斥关系 $|I_M\cup I_W|=U_M+U_W-O$。从经过时间减去活动并集得到其他开销。并行工人时长之和不作为墙钟时间。原生回放采用 $|I_W|$，在线采用运行开始至完成的经过时间；验证和证据重执行另记账。

数据库工作代理。　SQLite 每 1,000 条虚拟机指令触发一次进度处理器。历史字段名为 `sqlite_vm_steps_lower_bound`，本文以回调数或其乘 1,000 的值作为工作代理。短查询可以为零，准备阶段及数据库版本也会影响回调行为，因此不将其写成精确指令数。A14 的 19.5 倍是 39/2 次回调之比。

指标分工。　五场景主要工作量坐标依次为图论文记录读取数、原生回归用例数、SQLite 进度工作代理、指标值读取数和业务记录读取数。其余原生坐标仍全部进入支配判断。主要坐标分母为零时不计算节省比例，底表保留绝对值。交付率为已提交并评分阶段数除以计划阶段数。Q_1 检查输出契约，Q_2 检查证据和状态，G 为二者合取。工作量为事件求和向量，支配关系保留资源取舍。S_W, S_T, D 比较指定计时域中的工作和收益。$A_{\mathrm{rel}}, A_{\mathrm{irr}}$ 测量有效前缀后的修复和保持。增量工作、模型请求、时间与费用说明更新代价。前缀审计区分答案变化、证据刷新和可复用状态。

B　来源和改造细节

图数据。　STaRK 冻结版本为 `88269e23e90587f99476c5dd74e235a0877e69be`。原切片有 16,550 个节点和 149,765 条边；Stanford、MIT、Tokyo 切片分别有 16,058/142,401、14,376/126,927、13,167/120,386 个节点/边。扩展过程在指定机构中按种子抽取作者，保留发表记录和外向引用。焦点作者与原集合不重叠，引用节点有重叠。四簇分配 8/4/4/4 个父任务。

代码数据。　Requests 固定在 `b25c87d7cb8d6a18a37fa12442b5f883f9e41741`，ItsDangerous 固定在 `096c8d42545d3b68ea21a4f890fb2b2d8979c0bd`。packaging 和 python-dotenv 使用发布的 25.0 与 1.1.1 源码包，并记录 SHA-256。四簇分别分配 4/4/6/6 个父任务。原始、植入和修复快照独立保存，公开预期与当前观察分离。用例绑定包、检查名、用例名和版本；有效结论要求精确指出范围内失败项。

关系数据。　BIRD debit 与 financial 各四个父任务，Chinook 与 Northwind 各六个。消费任务聚合指定年份和客户；贷款任务聚合地区与状态；采购任务统计去重订单数、行数量和行金额，Northwind 应用折扣。相关变化改变对象集或受控数据值。原生汇总函数与等价只读 SQL 都可以通过验证。

遥测数据。　RCAEval 扩展文件固定版本为 `afeacb11bcc94dadfd1c8f483ee4377b2b8b614e`。原 checkout 簇八个父任务，currency CPU、product-catalog delay 和 Train Ticket order CPU 各四个。保留指标、日志、链路和注入时间。公开切分点及过滤条件确定期望量，相关卡片只移动切分点。任务评价源遥测派生的诊断报告。

应用数据。　四份 AppWorld 导出来自 `b0a8eae_1`、`22cc237_1`、`3fcc458_1`、`90adc3f_1`，父任务分配为 4/4/6/6。后两份分别包含六/四个播放列表、32/43 个支付请求和各 106 条用户记录。适配器在导出记录上实现本地状态变化：播放允许任一满足时长的列表，下载保持既有集合，支付按成员身份替换为 $\max(0,\mathrm{share}-\mathrm{paid})$。验证器检查最终状态。

C　模型配置与验收

全部模型通过 OpenRouter 调用，记录 provider、量化信息及请求参数。六个端点按开源模型家族归组，四个归为闭源 API；Qwen3.8 Flash 是日志中的生产端点，未绑定到某个公开检查点。最终新增 Grok 4.3、MiniMax M3、Gemini 3.7 Flash、GPT-6 Luna、GLM-5.3 Flash。Mistral Small 4 在正式阶段开始前持续限流，由 GLM 替换。

开发阶段冻结 JSON 对象和推理设置：GLM、Gemini 3.7、Luna 使用低推理，Grok 和 MiniMax 关闭推理。早期模型使用记录的兼容配置。全体保持相同原生工人和任务预算。在线配对匹配采集组及准入段，GLM 延后采集单列一组。原生回放在共同批次执行，Python 为 3.13.4，SQLite 为 3.49.1。

任务层验收通过 784 项，扩展契约验收通过 19 项，等价证据验收通过 11 项。非对象答案保护使 20 个畸形例子均被拒绝，并保留正常评分分支。等价性审计恢复两个 MiniMax 有效阶段，不改变模型响应及轨迹。四条传输错误占位记录不算模型 JSON 格式错误，仍保留于物理台账。

新增五模型有 3,000 个逻辑阶段、3,008 个物理阶段尝试；2,994 个逻辑阶段提交并评分，六个没有提交。四个物理请求保留未知费用预约。质量、交付和传输状态独立保存；最终 6,000 个逻辑阶段全部具有终态记录。

D 补充结果与分母

初始、相关和无关条件的无条件有效数分别为 1,479、862、1,532，分母均为 2,000。条件更新比较中，相关与无关有效数分别为 807、1,468，分母为 1,479。差异来自无条件更新还包含初始无效状态的继续执行。

中等任务一工人回放中，121/467 对正向衰减，14/467 对无正收益，332/467 对至少等比例兑现，父任务等权差距为 -7.9 个百分点，区间 $[-15.6, 1.0]$。四工人相应为 108、27、332 对，平均差距 -6.0 个百分点。

相同 116 对方案中，四工人原生节省比在线节省高 41.3 个百分点，区间 24.4–61.1；去掉本地准入后为 24.2 个百分点，区间 13.9–34.5。统计先在父任务内部平均，再在 37 个父任务间平均。

来源感知适应分析先在父任务内平均有效重复，再做场景内来源簇和父任务重采样。Luna 的相关更新父任务等权估计为 83.3%，区间 76.7–89.7；GLM 为 81.1%，区间 74.0–87.7。这与按有效重复数直接合并略有不同。全部十模型共同通过的初始交集仅八个父任务–重复单元，因此另提供每对模型的共同支持集。

E 相关工作覆盖映射

WorFBench v3 以结构匹配为主，并报告下游执行及计时；FlowMind v1 评价执行与重建工作流，包含 token 和工具分析；AgentBoard 报告进度和过程分析；AppWorld 通过应用状态检验结果。ClawArena-Team v2 具有执行评分、分阶段变化、权限及模态指标和使用量分析。OrchBench v1 通过确定性模拟测量质量、工期和 token。矩阵按照本文操作定义映射，对模拟域或粒度不同的量标记部分覆盖。最后一列要求从已验证完成前缀测量新增成本，并有相关/无关对照。

F 复现材料

底表包含 6,000 个阶段、5,006 对初始比较、各工作坐标、计时资格、前缀审计、适应比较池与来源敏感性分析。绘图代码直接使用这些表。完整研究归档索引初始计划、修订、观察、物理尝试及不可变源快照。任务卡和验证器代码独立保留。正文采用最终审计数值，开发探针和早期极复杂先导实验单独归档。

Model	Submitted	Q_1	G	Initial G	Related G	Irrelevant G
DeepSeek V4 Pro 0813	600/600	295/600	269/600	117/200	9/117	117/117
Kimi K2.6	596/600	397/600	374/600	153/200	52/153	152/153
Qwen3.8 Flash	575/600	410/600	402/600	159/200	72/159	152/159
Gemma 4 31B	571/600	458/600	406/600	161/200	81/161	161/161
GLM-5.3 Flash	600/600	550/600	526/600	184/200	150/184	182/184
MiniMax M3	600/600	97/600	52/600	19/200	0/19	19/19
Gemini 3.8 Flash	599/600	531/600	530/600	196/200	135/196	196/196
Gemini 3.7 Flash	600/600	537/600	534/600	197/200	140/197	197/197
Grok 4.3	594/600	270/600	221/600	97/200	3/97	96/97
GPT-6 Luna	600/600	563/600	559/600	196/200	165/196	196/196

Table 2: 精确分母。Submitted 表示已提交并评分；最后两列以初始有效为条件，因此不是相应 200 个更新阶段的无条件有效数。

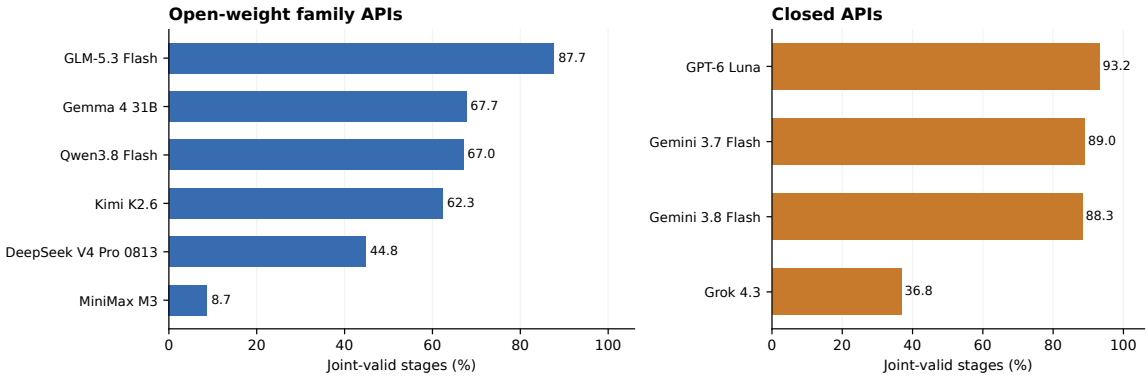


Figure 6: 按端点家族分组的描述性质量排行。分数为 600 个阶段的有效率；不合并工作量、时间及适应指标。

Evaluation	Executed outcome	Native work vector	Work–time pairing	Relevant updates	Valid-prefix cost
WorFBench	○	–	–	–	–
FlowBench / FlowMind	✓	–	–	–	–
AgentBoard	✓	–	–	–	–
AppWorld	✓	–	–	–	–
ClawArena-Team	✓	–	–	✓	–
OrchBench	○	○	○	–	–
WELD	✓	✓	✓	✓	✓

Table 3: 按本文操作定义映射的已报告测量。勾选为直接覆盖，圆圈为相关但测量域不同，横线为未单独报告该协议。Native work vector 保留领域单位；Work–time pairing 配对比较有效方案的原生工作与实际时间；Valid-prefix cost 测量有效完成前缀后的新增代价。